

1 Conditional Diffusion Models

1.1 Describe your implementation details and the difficulties you encountered.

我參考了Conditional_Diffusion_MNIST (https://github.com/TeaPearce/Conditional_Diffusion_MNIST) 這篇的做法。並且將 MNIST-M dataset 的 0-9 標成 0-9, SVHN dataset 的 0-9 標成 10-19, 直接用 20 個 condition (0-19) 去訓練。

implementation details:

- n.epoch: 100
- n.T: 500
- n.classes: 20
- n_feat: 128
- learning rate: 1e-4
- w (guidance strength when inference): 5

difficulties I encountered :

一開始為了生成品質較好的照片, 我將 ContextUNet 的 n_feat 設為 256, 但發現 inference 時會超過助教規定的時間, 所以後來就把 n_feat 改成 128, 這樣就能在時間限制內跑完了。

1.2 Show 10 generated images for each digit (0-9) from both MNIST-M and SVHN dataset



Figure 1: MNIST-M



Figure 2: SVHN

- 1.3 Visualize a total of six images from both MNIST-M and SVHN datasets in the reverse process of the first “0” in your outputs in (2) and with different time steps.




Figure 3: MNIST-M




Figure 4: SVHN

2 DDIM

2.1 Generate face images of noise 00.pt to 03.pt with different eta in one grid. Report and explain your observation in this experiment.



Figure 5:

由上到下分別是 $\eta=0.0$, $\eta=0.25$, $\eta=0.5$, $\eta=0.75$, $\eta=1.0$

由左到右分別是 00.pt, 01.pt, 02.pt, 03.pt

η 越大，加入的隨機 noise 對原本的 noise 的影響就越大。

若 η 為 0，用同一個 UNet weight 對同一個 Noise Sampling 出來的圖片會相同。

若是加了 η ，圖片的隨機性就會越大。

可以看到圖片中， η 越大的照片就越不像原本 $\eta=0$ 的照片。

2.2 generate the face images of the interpolation of noise 00.pt and 01.pt.



Figure 6: slerp




Figure 7: linear

使用 slerp 插值生成的人臉圖片很自然，因為 slerp interpolation 保持了在高維空間中的球面結構，產生的點會沿著兩個向量之間的最短路徑移動，從而保持了插值過程的連貫性；而 linear interpolation 是直接每個像素上進行插值，所以可能導致了一些像素值的不合理變化，產生的圖片很奇怪。

3 Personalization

3.1 Conduct the CLIP-based zero shot classification. Explain how CLIP do this, report the accuracy and 5 successful/failed cases.

CLIP 透過大量圖像-文本配對的對比學習，在語義空間中建立了圖像和文本之間的通用關聯，而這些關聯不依賴於特定的類別。因此，即使在遇到訓練中未見過的類別或描述時，CLIP 依然可以通過語義相似性來識別圖像。這使得 CLIP 能夠應對未見過的概念，從而做到 zero-shot classification。

Accuracy: 56.36% (1409/2500)

Successful Cases:

Image: 3_483.png, True Label: rabbit, Predicted Label: rabbit

Image: 16_486.png, True Label: skunk, Predicted Label: skunk

Image: 33_458.png, True Label: mouse, Predicted Label: mouse

Image: 11_481.png, True Label: dinosaur, Predicted Label: dinosaur

Image: 2_482.png, True Label: camel, Predicted Label: camel



Figure 8: 3_483.png




Figure 9: 16_486.png




Figure 10: 33_458.png




Figure 11: 11_481.png



Figure 12: 2_482.png

Failed Cases:

Image: 11_459.png, True Label: dinosaur, Predicted Label: willow_tree

Image: 42_476.png, True Label: cup, Predicted Label: lamp

Image: 23_485.png, True Label: pine_tree, Predicted Label: oak_tree

Image: 3_493.png, True Label: rabbit, Predicted Label: willow_tree

Image: 27_464.png, True Label: bee, Predicted Label: willow_tree



Figure 13: 11_459.png




Figure 14: 42_476.png




Figure 15: 23_485.png



Figure 16: 3_493.png




Figure 17: 27_464.png

3.2 What will happen if you simply generate an image containing multiple concepts?

Share your findings and survey a related paper that works on multiple concepts personalization, and share their method.

我訓練了 "`<new3>`" 這個 token，concept 來自 `hw2.dataset/cat` 中的黑貓。當我給定 `prompt = "a <new1>next to <new3>"`，會生出下面兩張照片。



Figure 18: multi-concepts example 1



Figure 19: multi-concepts example 2

可以看到它並沒有生出包含一隻狗和一隻黑貓的圖片，而是只生出一隻動物，看起來融合了原本的狗和黑貓的特色。這可能是因為訓練時都只考慮了單一概念場景，所以模型對於處理 tokens 之間的關係較有困難，無法生出把兩個 concept 並排放置的圖片。

Multi-Concept Customization of Text-to-Image Diffusion (https://openaccess.thecvf.com/content/CVPR2023/html/Kumari_Multi-Concept_Customization_of_Text-to-Image_Diffusion_CVPR_2023_paper.html) 這篇論文提出了一種實作 multiple concepts personalization 的方法。對於 multi-concepts 的訓練，作者為不同的概念引入了不同的 modifier token V^* ，這些 token 用於代表新的概念，並且是以不常見的 token 進行初始化，以避免干擾現有概念。

此外，作者發現 diffusion model 中 cross-attention layers 的參數量只佔總參數量的 5%，卻對 latent feature 的影響很大。所以在訓練過程中，只對這些 modifier token 以及 diffusion model 中 cross-attention layers 的 W^k 和 W^v (key 和 value projection matrices) 進行微調。

因為 attention 機制本身支持組合性（模型會對每一個輸入片段進行比較，計算它們之間的關聯性並將這些資訊加權組合生成輸出），這意味著模型可以靈活地組合不同的輸入片段並形成新的關聯性。因此，在加入新的概念時，只需更新 key 和 value 矩陣，模型仍然可以利用原本參數中所包含的其他概念之間的關係。這使得在生成包含多個概念的圖像時，模型能夠合理地將這些概念組合在一起，並保持圖像的連貫性。且因為大多數參數都保持不變，所以可以確保模型不會失去先驗知識。

4 References

https://github.com/TeaPearce/Conditional_Diffusion_MNIST

https://github.com/rinongal/textual_inversion

https://openaccess.thecvf.com/content/CVPR2023/html/Kumari_Multi-Concept_Customization_of_Text-to-Image_Diffusion_CVPR_2023_paper.html